

Les métiers de la data au service de la statistique publique africaine

Logiciels propriétaires coûteux, cycles de publication trop longs, faible reproductibilité : comment les métiers de la data et le package open source statAfrikR modernisent les instituts nationaux de statistique (INS) d'Afrique.

Par Dikers AMOKO · Publié le 8 juillet 2026 · statafrikr.org

EN BREF · IN BRIEF

FR — La numérisation transforme la production statistique mondiale, et les métiers de la data en deviennent des acteurs incontournables. Les INS africains doivent intégrer ces compétences pour rester pertinents. statAfrikR — package R open source publié sur le CRAN — apporte une réponse souveraine et pérenne : un outil gratuit, fonctionnel hors ligne, couvrant tout le cycle de production statistique.

EN — Digitisation is reshaping how official statistics are produced, and data professions are now central to the value chain. statAfrikR — an open-source R package on CRAN — offers a sovereign, sustainable answer: a free, offline-capable tool covering the whole statistical production cycle.

La statistique publique africaine se trouve à un moment charnière. La révolution numérique bouleverse les méthodes de production, d'analyse et de diffusion des données, tandis que les INS africains affrontent des défis structurels profonds. La question n'est plus *si* la modernisation aura lieu, mais *avec quels outils* — et au service de qui.

La statistique africaine à un carrefour

Des licences qui coûtent cher

Stata : 500 à 3 000 \$/an ; SAS Enterprise : plus de 50 000 \$/an. Pour des budgets souvent inférieurs au million de dollars, c'est lourd — et un code fermé, non adaptable.

Des cycles trop longs

Plus de 18 mois entre collecte et publication d'une enquête ; 3 à 5 ans pour un recensement. Traitements manuels, peu d'automatisation.

Une reproductibilité fragile

Traitements interactifs, code non documenté, ni contrôle de version ni tests : vérifier, mettre à jour et transmettre devient très difficile.

Le halo des métiers de la data

Ces profils ne remplacent pas le statisticien : ils enrichissent ses capacités. On les situe le long d'un axe allant des techniques informatiques aux usages métier (Galiana & Lefebvre, 2026).

Data engineer

Intégration des données (pipelines), déploiement, MLOps. Orienté infrastructure : rend un traitement robuste et rejouable.

Data scientist

Analyse, entraînement des modèles, préparation et labellisation. Interface technique/métier — outillé en priorité par statAfrikR.

Data analyst

Exploration, visualisation, recommandations. Orienté décision : relie les indicateurs à l'action publique.

Pour les INS africains, ces rôles peuvent être exercés par les statisticiens eux-mêmes, progressivement formés à R, ou par de nouvelles recrues spécialisées.

R, standard mondial — statAfrikR, son adaptation africaine

R est le langage de référence de la statistique mondiale : utilisé par l'INSEE, Eurostat, l'ONU, la Banque Mondiale et le FMI, il compte plus de 20 000 packages sur le CRAN. Gratuit, ouvert, porté par une communauté internationale. **statAfrikR** en est l'adaptation africaine la plus avancée : sa version **v0.1.0** propose **40 fonctions en 5 modules** et a été téléchargée près de **800 fois en trois mois**. Il fonctionne hors ligne, en français, sur des ordinateurs modestes.

« Un INS dont les données sont propres, traçables et harmonisées est un INS qui inspire confiance. Les décisions de politique publique ne sont jamais meilleures que les données sur lesquelles elles reposent. »

Quatre valeurs guident le projet : **souveraineté statistique**, **reproductibilité**, **harmonisation** (AFRISTAT, ONU, ODD, Agenda 2063) et **inclusion** (gratuité GPL-3, hors ligne, matériel modeste).

Un package qui couvre tout le cycle

Collecte

import_kobo(), import_odk() via API ; import_stata/spss/sas() sans perdre labels ni pondérations ; import_cspro() pour les RGPH.

Traitement

check_types(), check_na(), nettoyer_libelles() (AFRISTAT), recoder_variable(), valider_qualite_donnees() (rapport /100, export PDF).

Analyse

appliquer_ponderations(), stat_descr(), tab_croisee() ; calcul_ipm(), calcul_idh(), decomposer_inegalite().

Visualisation

theme_ins(), palette_ins() ; pyramides des âges, tendances, cartes thématiques en PNG haute résolution et SVG.

Diffusion

generer_rapport() (Word/PDF), generer_metadonnees_ddi(), exporter_sdmx(), anonymiser_donnees().

Et la suite (v0.2.0)

13 jalons : FGT, 20 indicateurs ODD, IPM Alkire-Foster, 888 subdivisions cartographiées, module PIB, dashboard Shiny.

Trois cas concrets

EHCVM — Burkina Faso

8 500 ménages, 13 régions,
KoboToolbox. import_kobo →
check_na/nettoyer_libelles →
ponderations → calcul_fgt →
carte_thematique →
generer_rapport.

RGPH-4 — Tchad

Base CSPro de 3,2 M de
ménages, 180 variables, 22
régions. import_cspro() charge le
.dcf. Score qualité 87/100,
rapport PDF automatique.

Suivi ODD — Sénégal

Rapport annuel de l'ANSD
automatisable (module ODD
v0.2.0) : 20 indicateurs,
cartographie des disparités,
génération Word/PDF.

La codification automatique par machine learning

L'INSEE a industrialisé un modèle qui attribue automatiquement le code d'activité d'une entreprise à partir du libellé rédigé en langage naturel lors de sa création. L'intérêt n'est pas seulement le gain de temps : c'est la **démarche** — expérimenter un modèle, le mettre en production de façon fluide, puis surveiller sa performance dans la durée (approche dite MLOps).

Cette recette se transpose directement aux besoins africains : à partir de descriptions libres saisies dans un recensement (RGPH) ou une enquête ménage (EHCVM), un modèle pourrait attribuer le **code d'activité** (nomenclature internationale CITI/ISIC) et le **code de profession** (CITP/ISCO).

Le point clé, souvent négligé, est la **surveillance du modèle** : entraîné sur des données passées, il perd en pertinence quand la réalité change — essor de l'économie des plateformes ou de la livraison à domicile, qui fait apparaître des libellés inédits. Un cycle d'amélioration continue (collecte de cas annotés, réentraînement) devient indispensable. C'est le type de chantier expérimental que statAfrikR inscrit à sa feuille de route.

Reproductibilité : Git, tests, CRAN

Le **versionnement du code** est l'une des transformations les plus profondes qu'apporte la culture data. Avec **Git**, chaque modification est tracée, la collaboration devient fluide et les résultats reproductibles : le code cesse d'être un fichier isolé pour devenir un **bien commun institutionnel**. Chaque fonction de statAfrikR est couverte par des **tests automatisés**, et la publication sur le **CRAN** soumet l'outil aux mêmes exigences que les packages de l'INSEE, d'Eurostat ou de la Banque Mondiale — avec la transparence de l'open source.

Cap 2026-2030

La **v0.2.0** (septembre 2026) apporte les indicateurs les plus demandés : indices **FGT**, **20 indicateurs ODD**, **IPM Alkire-Foster**, une cartographie de **888 subdivisions** hors ligne, un module **PIB** et un **dashboard Shiny**. Autour du package : la **statAfrikR Academy** (formation certifiante de 10 jours, trois niveaux) et une **communauté panafricaine** sur Discord, premier réseau de statisticiens R du continent.

Une modernisation souveraine

La transformation ne se décrète pas : elle se construit, progressivement, avec des outils adaptés, des agents formés et une vision institutionnelle claire. statAfrikR n'est pas un outil parmi d'autres — c'est une infrastructure statistique pensée pour les réalités africaines, développée par des statisticiens africains, maintenue par une communauté africaine et publiée sous licence libre.

Sources & références. Galiana, L. & Lefebvre, O. (2026). *Qu'apportent les métiers de la data à la statistique publique ?* Courrier des statistiques, n°15, pp. 95-116, INSEE. — Foster, Greer & Thorbecke (1984), *Econometrica* 52(3). — Alkire & Foster (2011), *Journal of Public Economics* 95(7-8). — Amoko-Mongamo, D.-D. (2026). *statAfrikR* (v0.1.0), CRAN.